Bases de Datos 2

Teoría 10

Federico Orlando

Data warehouse

Data warehouse

Motivación

¿Qué fuentes de datos existen en una organización?

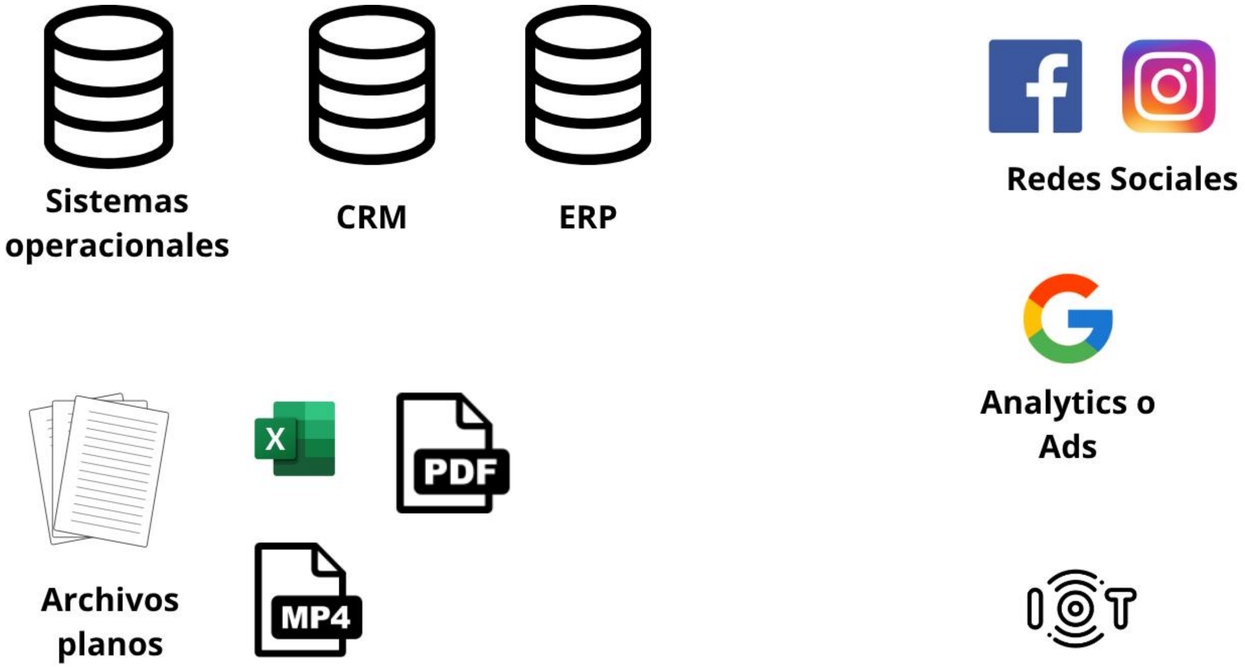

¿Cómo obtenemos información esencial para el negocio de estas fuentes tan diversas?

Data warehouse

Historia

Según W. H. Inmon (considerado por muchos el padre del concepto), un data warehouse es un conjunto de datos orientados por temas, integrados, variantes en el tiempo y no volátiles, que tienen por objetivo dar soporte a la toma de decisiones.

Según Ralph Kimball (considerado el principal promotor del enfoque dimensional para el diseño de almacenes de datos), un data warehouse es una copia de los datos transaccionales específicamente estructurada para la consulta y el análisis.

Data warehouse

Definición

¿Qué es un Data Warehouse? ¿Es un tipo de Base de Datos?

Un **Data Warehouse** (**almacén de datos)** es un sistema que se utiliza para almacenar en un único repositorio grandes volúmenes de datos que provienen de múltiples fuentes de datos de la organización. A su vez, se encuentra altamente estructurado proporcionando una visión global, común e integrada de los datos, independientemente de cómo se vayan a utilizar posteriormente los mismos.

Está diseñado específicamente para el análisis y la generación de informes, no para el procesamiento de transacciones del día a día.

Data warehouse

Características

- *Integración*
- *Consistencia*
- *Variable en el tiempo*
- *No volátil*
- *Organización temática*

Data warehouse

Funciones y uso

- *Buisness Intelligence*
- *Informes y/o reportes gerenciales*
- *Decisiones basadas en datos*
- *Análisis de tendencias y comportamientos*
- *Data mining*
- *Machine Learning*

Data warehouse

Componentes

- *Data Sources*
- *Herramientas de ETL*
- *Metadata*
- *Base de datos*
- *Herramientas de consulta y análisis*

Data warehouse

ETL

- *Extracción*
- *Transformación*
- *Carga (Load)*

Data warehouse

Arquitectura

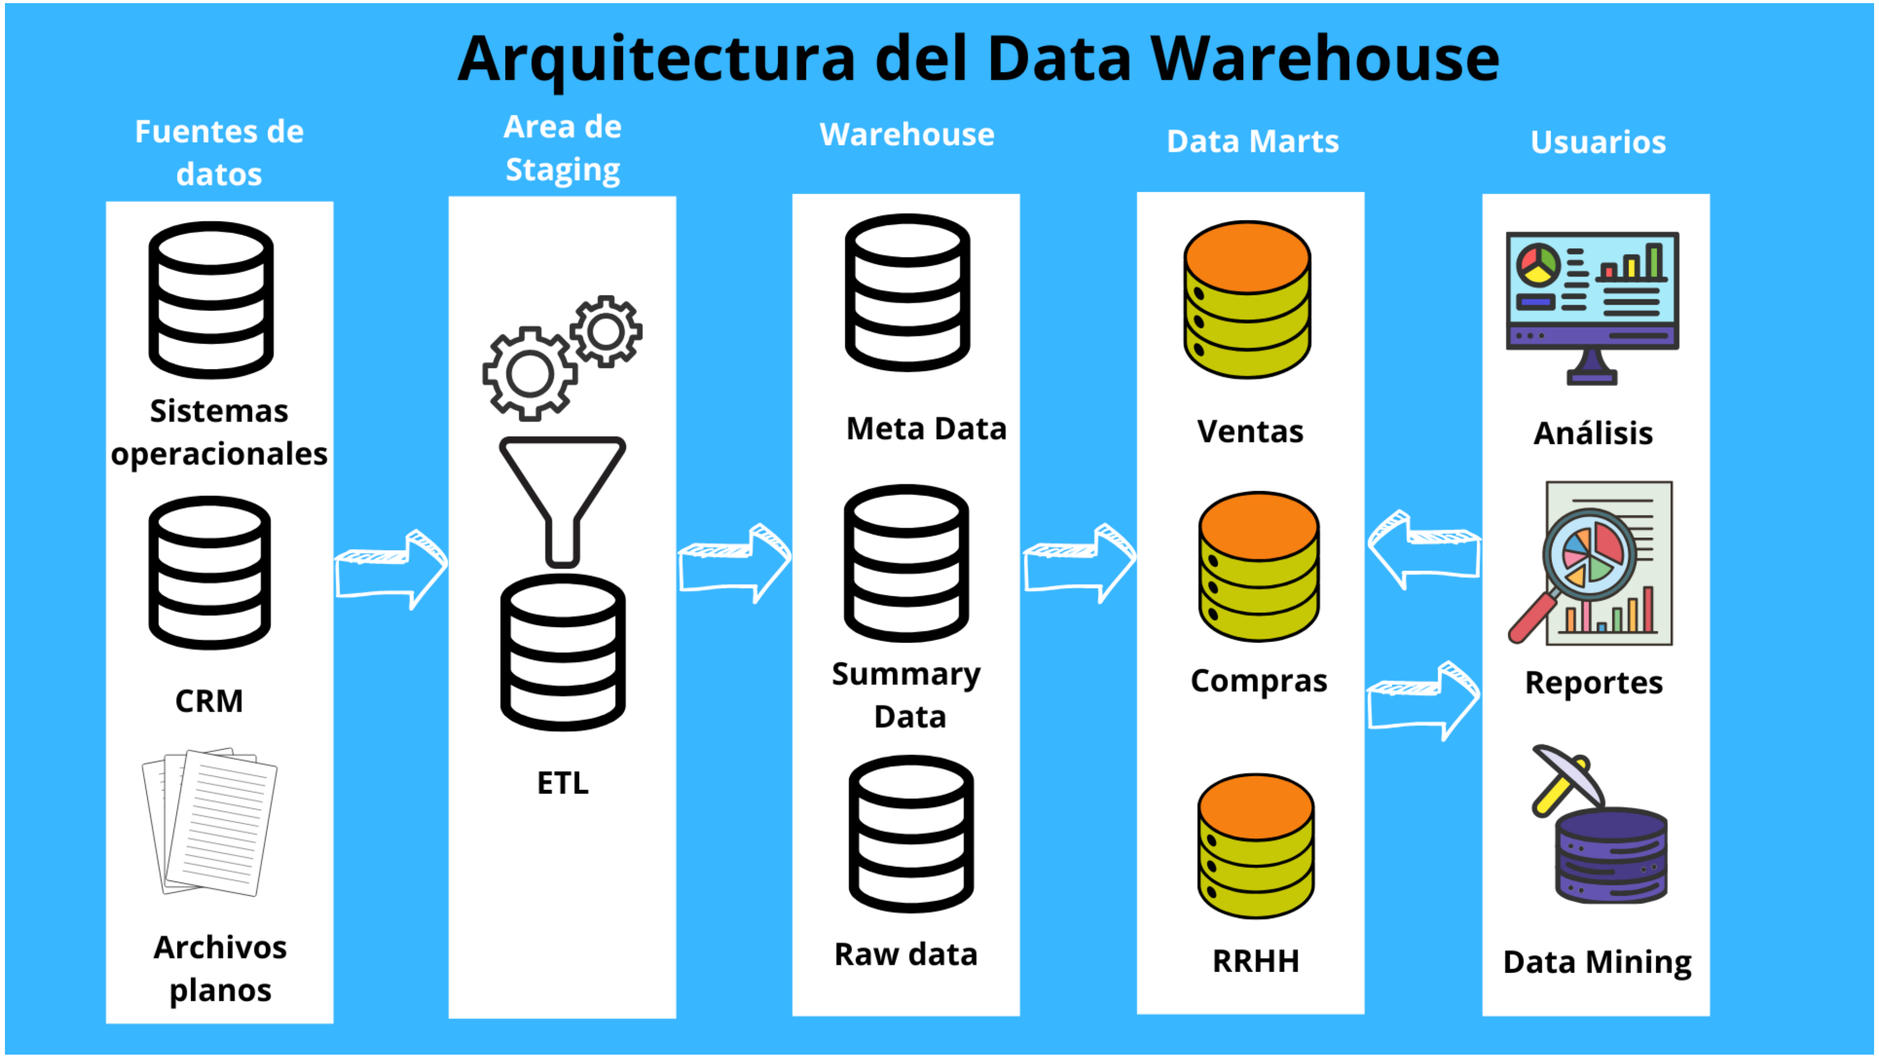

Data warehouse

Bases de Datos vs Data Warehouse

Bases de Datos	Data Warehouse
Orientada a transacciones	Orientado a consultas
Operativa	Análisis y toma de decisiones estratégicas
Proceso puntual	Proceso batch masivo
Estabilidad	Dinámica
Datos desagregados	Distintos niveles de agregación
Dato actual	Evolución del dato
Usuario de perfil bajo	Usuarios de perfil alto
Datos relacionados con lo operativo	Datos relacionados con el negocio

Data warehouse

Tablas

- **HECHOS (medidas)**: Son el objeto de los análisis y están relacionados con las dimensiones. Son tablas muy grandes y suelen estar desnormalizadas o en 3FN. A menudo incluyen diferentes agregaciones como máximo, mínimo, media, etc.

Almacena datos cuantitativos o numéricos sobre un proceso de negocio, como ventas, compras, o incidencias, para su análisis,

Una tabla de hechos suele tener dos tipos de columnas: claves foráneas para tablas de dimensiones y medidas, que contienen datos numéricos. Una tabla de hechos puede contener datos de hechos a nivel de detalle o agregado.

Data warehouse

Tablas

- **DIMENSIONES**: Representan factores por lo que se analiza un determinado área del negocio. Son pequeñas y usualmente están desnormalizadas.

Las dimensiones contienen los metadatos sobre los hechos.

Si la información necesita disponer de varios niveles de granularidad se crean jerarquías con las dimensiones. Por ejemplo la jerarquía fecha podría ser «día – semana – mes – trimestre – año». Las jerarquías de las dimensiones presentan relaciones n-1 de manera que un valor de un nivel sólo puede ser agrupado por un único valor de cada nivel inmediatamente superior en la jerarquía.

Data warehouse

Modelos

- *Estrella*
- *Copo de Nieve*
- *Galaxia o Constelación*

Data warehouse

Modelo Estrella

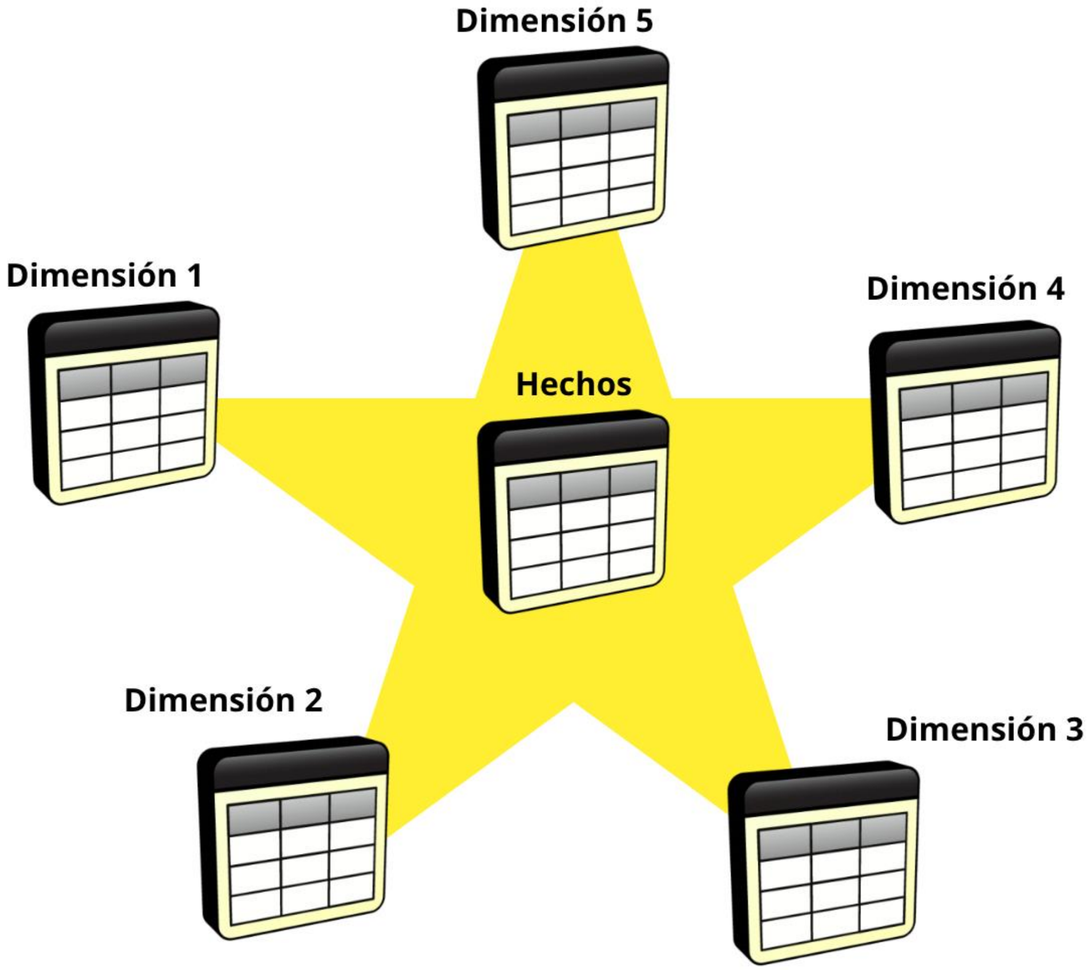

Data warehouse

Modelo Estrella

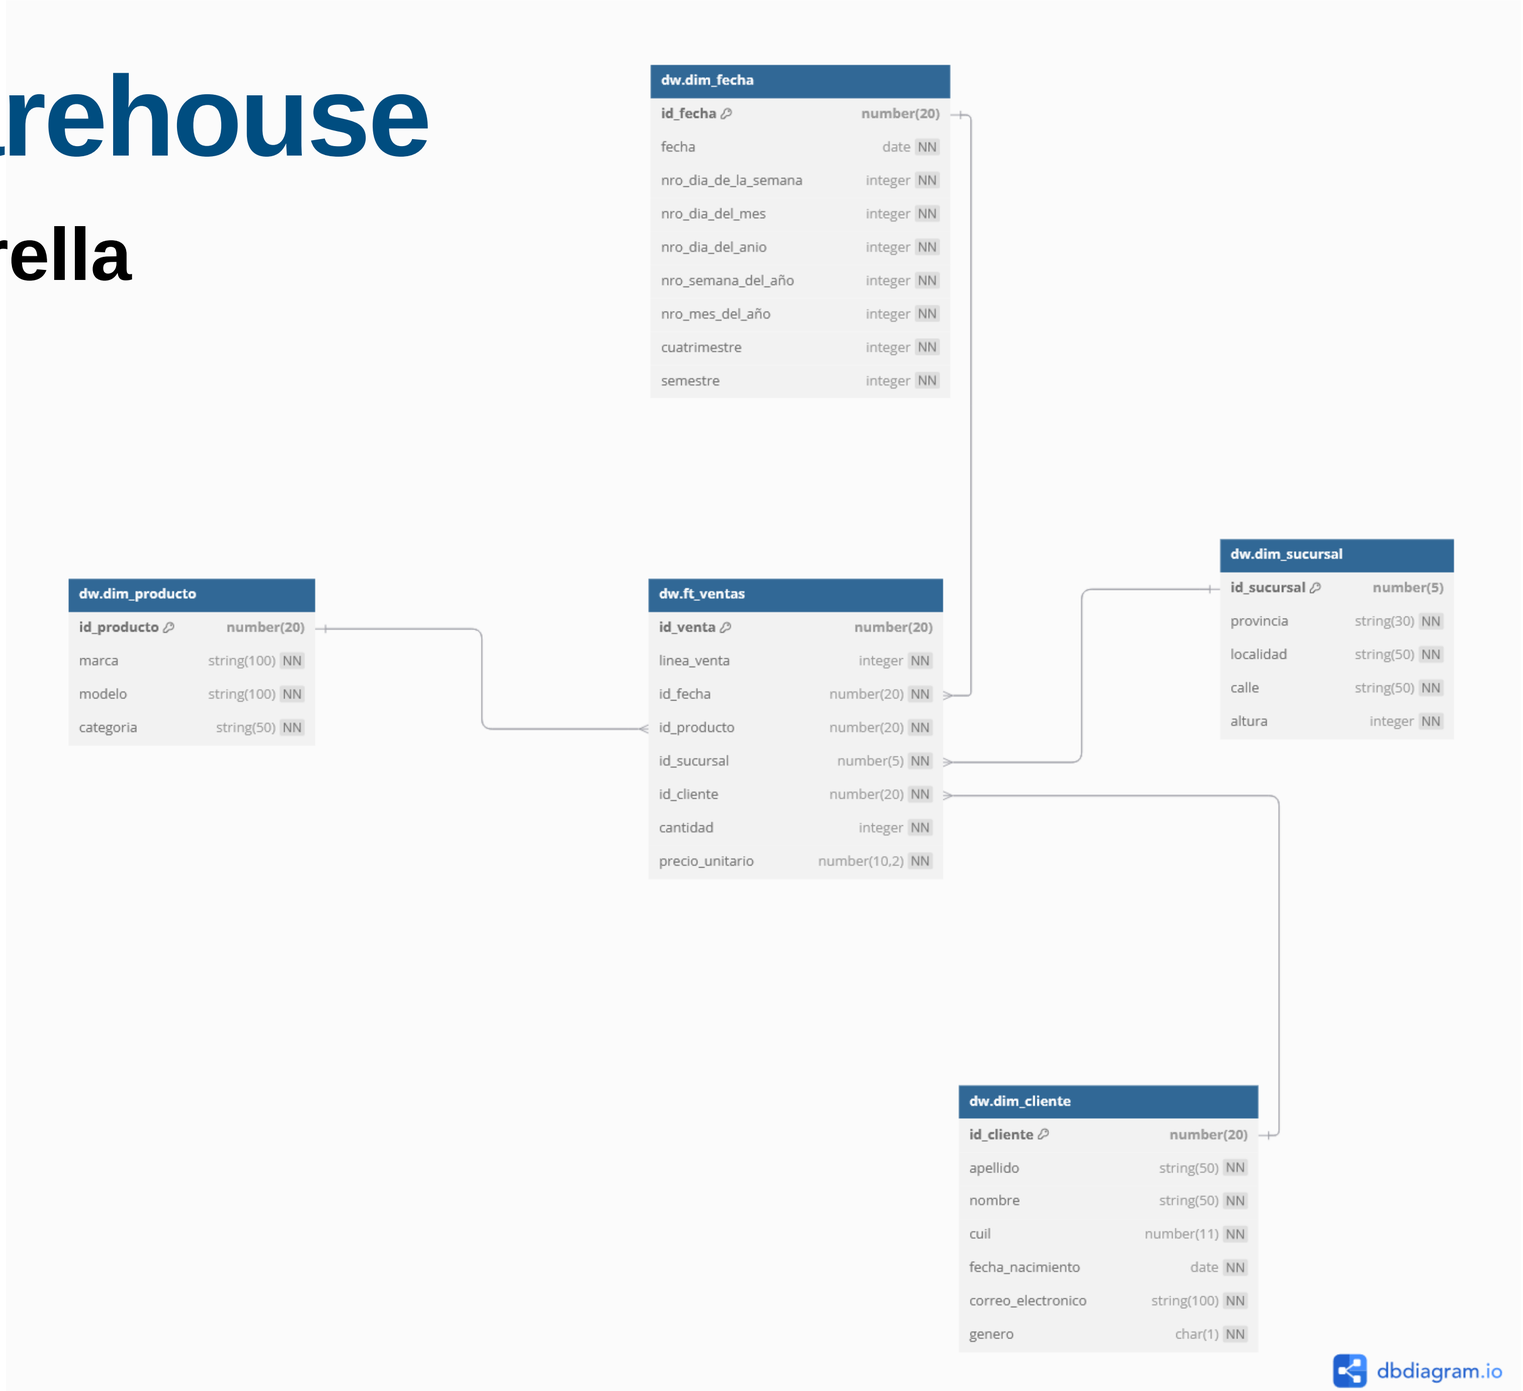

Data warehouse

Modelo Estrella

PROS

- *Es el más simple de todos los modelos, esto lo hace muy fácil de integrar en la organización, ya que es fácilmente comprensible.*
- *Es un modelo que tiene muy buen rendimiento en las consultas, ya que solamente involucramos un join entre los datos.*

Data warehouse

Modelo Estrella

CONTRAS

- *La escalabilidad puede ser peor, ya que existe un uso más ineficiente del almacenamiento.*
- *Trabajar con tablas desnormalizadas y redundancia de datos hace que el tamaño de la tabla pudiera ser grande y se produzca un tiempo relativamente largo de carga de datos en tablas de dimensiones.*

Data warehouse

Modelo Copo de nieve (Snowflake)

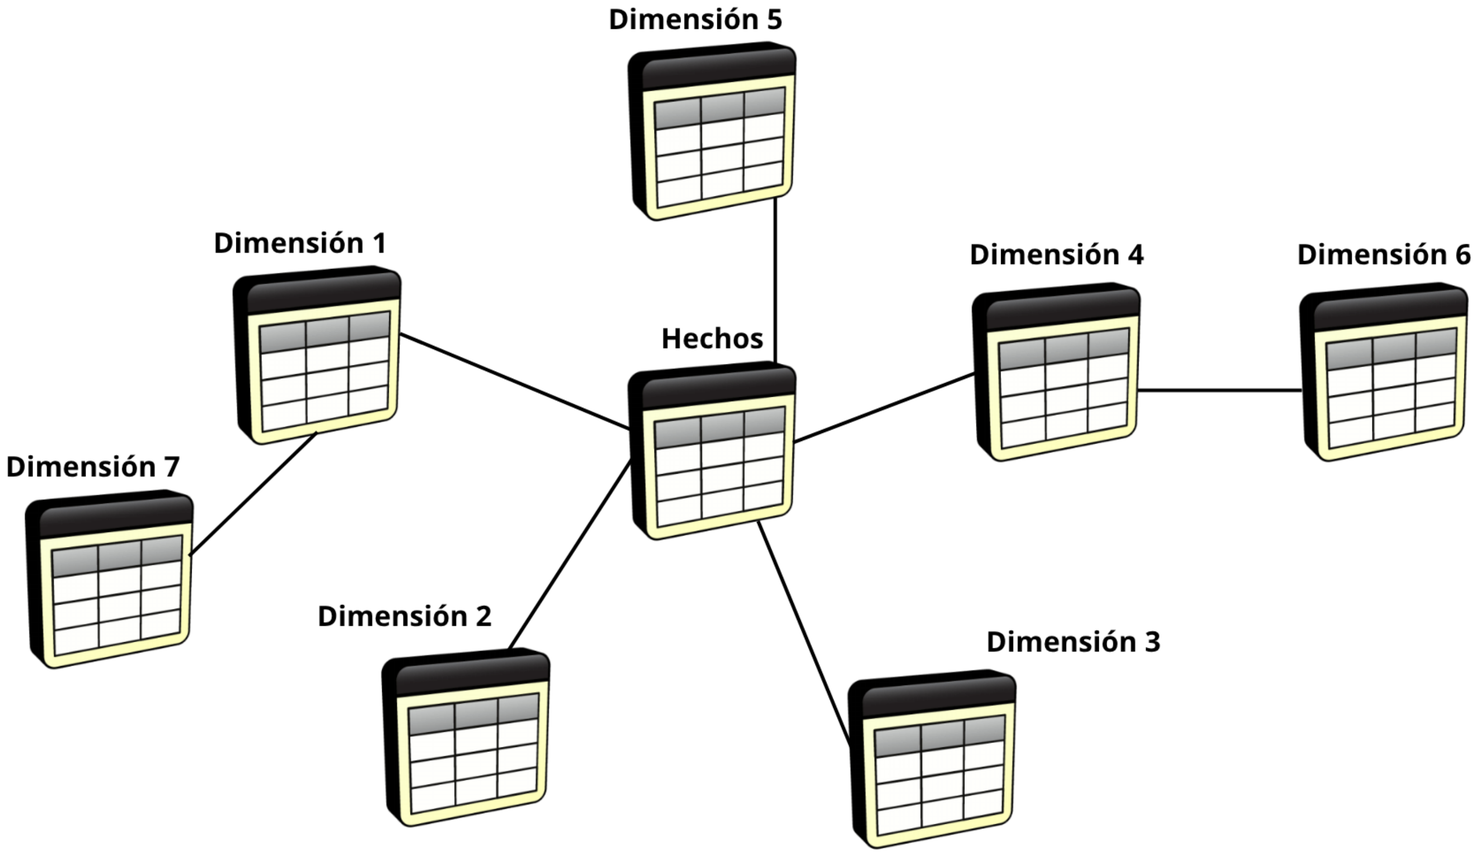

Data warehouse

Modelo Copo de nieve (Snowflake)

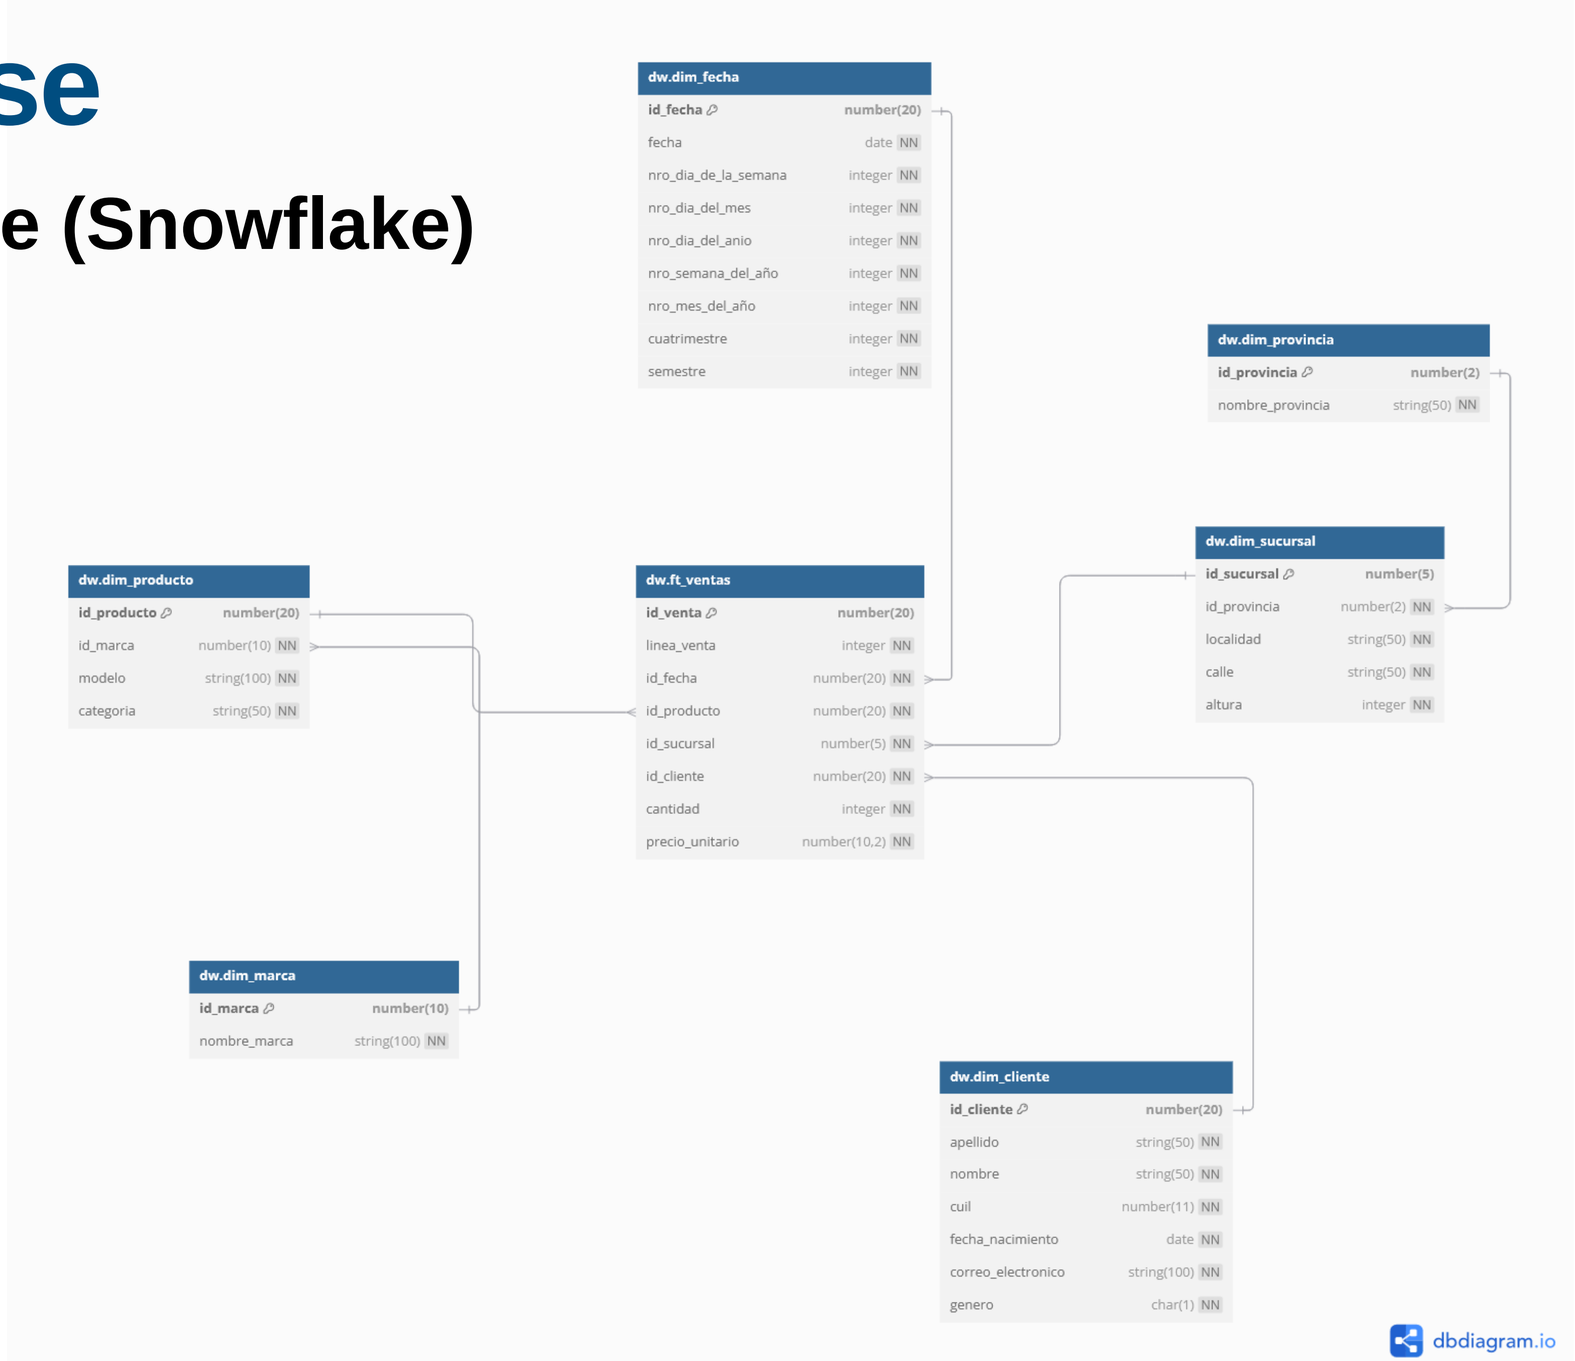

Data warehouse

Modelo Copo de nieve

PROS

- *Permite generar más contexto alrededor de una tabla de hechos.*
- *Trabajas con tablas normalizadas, se evita la redundancia de datos añadiendo más capas de contexto.*

Data warehouse

Modelo Copo de Nieve

CONTRAS

- *El código es mucho más complejo ya que pasamos a dos niveles de join a la hora de trabajar con una dimensión.*

Data warehouse

Modelo Galaxia

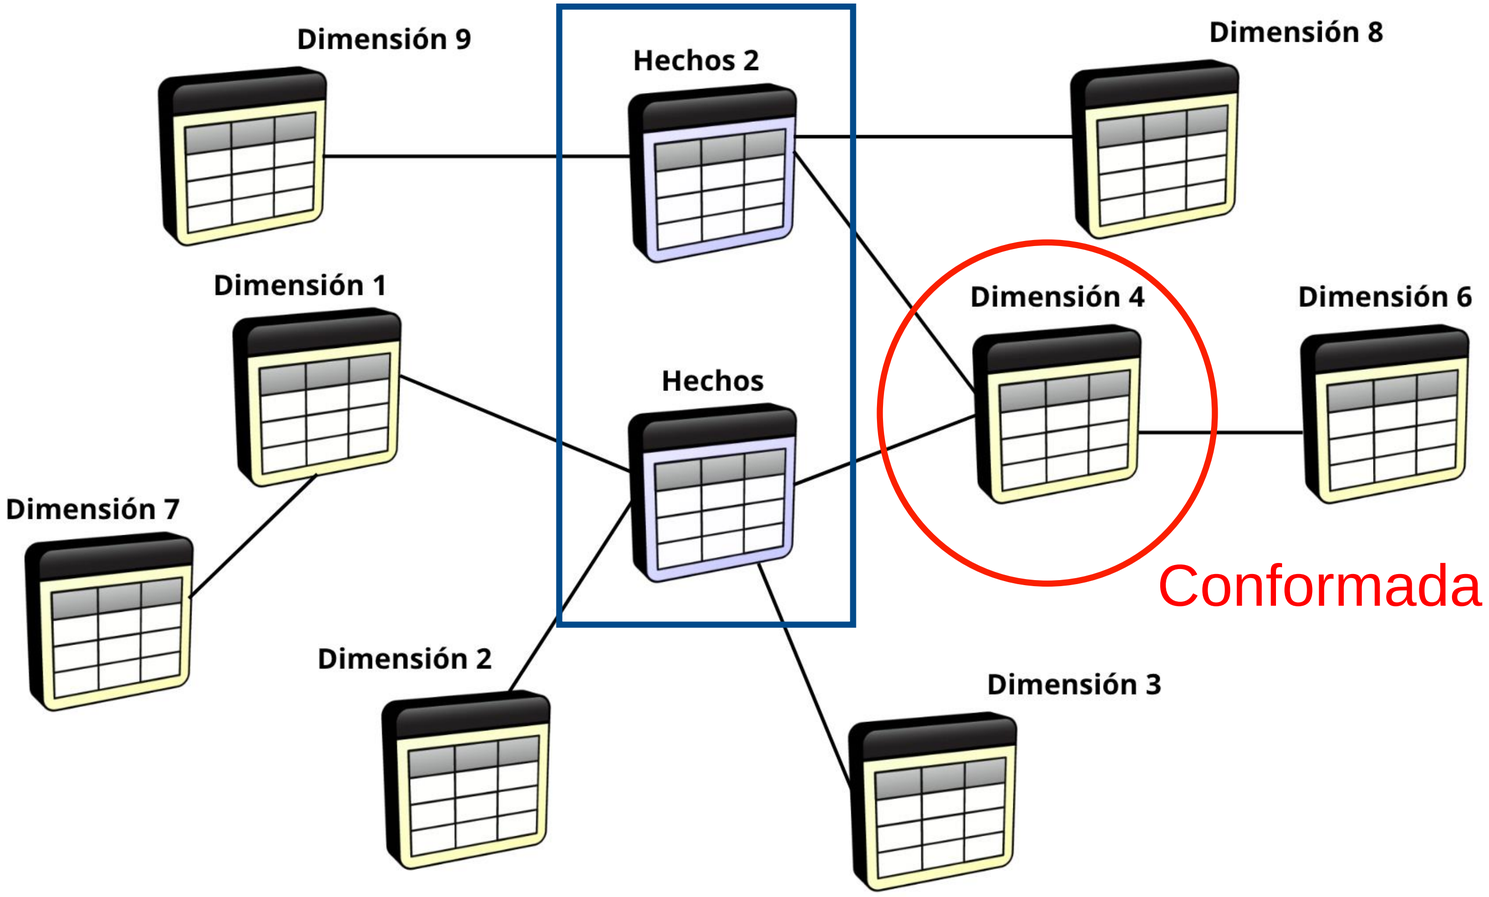

Data warehouse

Data Mart

Un Data Mart es un subconjunto de los datos del Data Warehouse orientado a un área específica con el objetivo de responder a determinados análisis o necesidades de dicha área,como pueden ser ventas o finanzas.

En un Data Mart independiente, los datos pueden recopilarse directamente de las fuentes. Tiene diversas funciones como organizar la información para posteriormente analizarla, realizar indicadores (KPI), evaluar los objetivos del sector que se está analizando, etc. El objetivo es realizar un análisis detallado sobre lo que ocurre en un negocio.

Data warehouse

Data Lake

- *Es un repositorio orientado a almacenar gran cantidad de datos, tanto estructurados como sin estructurar.*
- *Permite almacenar los datos tal cual vienen sin necesidad de ser transformados.*
- *Ejecuta diferentes tipos de análisis, dashboards y visualizaciones, además de generar procesos de big data, análisis en tiempo real y de Machine Learning que facilitan la toma de decisiones.*